2022年12月一实验七

【实验名称】

数据及文件操作练习

【实验目的】

- 1. 统计 hamlet.txt 中每个单词的出现频次,输出频次最高的 10 个单词。
 - 1) 保留介词、冠词、连词的情况下统计词频,并输出结果
 - 2) 去除介词、冠词、连词的情况下统计词频,并输出结果
- 2. 将整数 12345 分别写入文本文件 test.txt 和二进制文件 test.dat, 并比较两个文件的不同输出。

【实验内容】

- 1、程序清单
- (1) 统计每个单词的出现频次
 - 1) 保留介词、冠词、连词的情况下统计词频

```
import re
res = \{\}
# 只读打开文件
with open('./hamlet.txt', 'r') as f:
   txt = f.read()
for line in txt.splitlines():
   line = re.sub(r'[+=^$#!]', ' ', line) # 去除所有标点符号
   for word in line.split():
       flag = False
       if word[-1] == '-':
           up = word[:-1]
           flag = True
           break
       if flag:
           word = up + word # 拼接末位单词
           flag = False
       res.setdefault(word.lower(), 0)
       res[word.lower()] += 1
values = sorted(res.values())
sortedres = sorted(res.items(), key=lambda d: d[1], reverse=True)
for i in range(0, 10):
   print(sortedres[i][0])
```

```
2) 去除介词、冠词、连词的情况下统计词频
  import re
  res = \{\}
  # 只读打开文件
  with open('./hamlet.txt', 'r') as f:
      txt = f.read()
  for line in txt.splitlines():
      line = re.sub(r'[+=^$#!]', ' ', line) # 去除所有标点符号
      for word in line.split():
          flag = False
          if word[-1] == '-':
             up = word[:-1]
             flag = True
             break
          if flag:
             word = up + word # 拼接末位单词
             flag = False
          res.setdefault(word.lower(), 0)
          res[word.lower()] += 1
  values = sorted(res.values())
  sortedres = sorted(res.items(), key=lambda d: d[1], reverse=True)
  lista = ['the', 'a', 'an', 'at', 'on', 'behind', 'during', 'from',
           'into', 'and', 'but', 'or', 'so', 'however', 'although']
  count = 0
  for i in range(0, 20):
      if sortedres[i][0] not in lista:
          print(sortedres[i][0])
          count += 1
      if count == 10:
          break
(2) 将整数 12345 分别写入文本文件 test.txt 和二进制文件 test.dat
  a = '12345'
  with open('./test.txt', 'w') as f:
      f.write(a)
  with open('./test.dat', 'w') as f:
      f.write(a)
```

```
with open('./test.txt', 'r') as f:
    print(f.read())
with open('./test.dat', 'r') as f:
    print(f.read())
```

2、结果截图

- (1) 统计每个单词的出现频次
 - 1) 保留介词、冠词、连词的情况下统计词频

2) 去除介词、冠词、连词的情况下统计词频

```
import re
     res = {}
     with open('./hamlet.txt', 'r') as f:
         txt = f.read()
    for line in tyt calitlings().
          line (variable) word: str ' ', line) # 去除所有标点符号
          for word in line.split():
              flag = False
              if word[-1] == '-':
                 up = word[:-1]
                 flag = True
                 break
              if flag:
                 word = up + word # 拼接末位单词
                  flag = False
              res.setdefault(word.lower(), 0)
             res[word.lower()] += 1
     values = sorted(res values())
D:\vscode(python)>python -u "d:\vscode(python)\a3.py"
you
that
```

(2) 将整数 12345 分别写入文本文件 test.txt 和二进制文件 test.dat

【实验体会】

通过此次实验,使我更加熟悉了 python 中对于文件的操作和对于数据的处理,在数据的处理中,回顾了 re 库——正则表达式的使用,收获较大。